



FACULTÉ DES ARTS ET DES SCIENCES
DÉPARTEMENT D'INFORMATIQUE ET DE RECHERCHE OPÉRATIONNELLE

Rapport Final

Réalisé par
Mandi Teo Vigier, 20237155
CEDRIC KAMDEM
Ange Lilian Tchomtchoua Tokam, 20230129
30 Avril 2025

TRAVAIL PRÉSENTÉ DANS LE
CADRE DU COURS IFT 3710

Résumé

La Premier League anglaise est l'un des championnats les plus populaires et lucratifs au monde, générant chaque année des milliards de dollars de revenus et captivant un public mondial. Ce projet s'inscrit dans cette dynamique en exploitant les données massives générées par les matchs pour anticiper les résultats de la saison 2022-2023. Le but est de transformer l'information brute en prédictions utiles, afin de mieux comprendre les dynamiques sous-jacentes aux performances sportives.

Nous cherchons à répondre à une problématique précise : peut-on prédire de manière fiable les résultats futurs d'une saison de Premier League à partir des données historiques disponibles ? Pour cela, nous avons utilisé des données couvrant les saisons 2011-2022 et appliqué des méthodes d'apprentissage supervisé.

Trois modèles ont été développés : un classificateur bayésien naïf (simple, rapide, bien calibré), un réseau de neurones feedforward (FNN) pour capter les relations complexes entre variables, et un réseau de neurones récurrent (RNN) pour exploiter les dépendances temporelles. En complément, des modèles de référence comme le *Multinomial Naive Bayes* calibré et la régression logistique multinomiale pondérée ont été testés.

Parmi ceux-ci, la régression logistique pondérée s'est démarquée, combinant précision, robustesse aux déséquilibres de classe et interprétabilité. Toutefois, les limites liées aux facteurs non observables (blessures, transferts, événements tactiques) rappellent que ces modèles ne remplacent pas l'analyse humaine. Ils doivent être vus comme des outils d'aide à la décision pour analystes, clubs ou parieurs, capables de dégager des tendances et d'évaluer des scénarios, mais jamais de prédire l'imprévisible.

Introduction

Le football, plus qu'un sport, est un véritable phénomène culturel et économique à l'échelle mondiale. Parmi les championnats de football, la Premier League anglaise se distingue par son influence considérable, non seulement dans le domaine sportif mais également dans les sphères économiques et sociales. En 2022, la Premier League a généré plus de 8 milliards de dollars USD de revenus, se plaçant ainsi comme la ligue la plus lucrative au monde. À l'international, ses droits de diffusion ont été vendus pour plus de 6,6 milliards de dollars USD pour le cycle 2022-2025, établissant un nouveau record mondial. Ces chiffres témoignent du rôle central de la Premier League dans l'économie britannique et mondiale.

La Premier League est suivie chaque saison par des millions de téléspectateurs à travers le monde, grâce à des clubs de renommée mondiale. Ces équipes génèrent également une quantité massive de données à chaque rencontre. Le défi est alors de transformer cette richesse d'information en outils de prédiction efficaces.

L'objectif principal de notre travail est de développer un modèle capable de prédire les résultats des matchs de la saison 2022-2023. Ce choix est motivé par le fait que notre base de données s'étend jusqu'à la saison 2021-2022 : cela nous permet d'utiliser toutes les informations historiques disponibles pour entraîner nos modèles, puis de comparer nos prédictions aux résultats réels de la saison suivante. Cette méthodologie offre un cadre rigoureux pour évaluer la validité des approches retenues.

Trois modèles seront construits :

- Un **classificateur bayésien naïf**, qui servira de base simple, rapide et interprétable ;
- Un **réseau de neurones feedforward (FNN)**, pour capturer les relations non linéaires complexes entre les variables ;
- Un **réseau de neurones récurrent (RNN)**, afin de tirer parti de la structure temporelle des performances passées.

Au-delà de la performance pure, nous chercherons à comparer le comportement de ces trois modèles, pour mieux comprendre l’impact de la complexité algorithmique sur les résultats. Cela nous permettra de formuler des recommandations sur le niveau de sophistication nécessaire pour traiter efficacement ce type de problème.

Enfin, le choix de ce projet est aussi né d’une passion commune pour le football. Mais il repose surtout sur la conviction que l’analytique sportive peut avoir un véritable impact économique. À une époque où les clubs investissent massivement dans la data science pour optimiser leurs décisions, les travaux comme le nôtre peuvent contribuer à améliorer la précision des prédictions, et ainsi influencer les stratégies de recrutement, de sponsoring ou de diffusion télévisée

1 Méthodes

L’ensemble du code utilisé dans ce projet est entièrement original. Aucune portion de code externe n’a été réutilisée ou copiée. Toutes les fonctions, étapes de traitement, entraînement des modèles et visualisations ont été développées spécifiquement pour ce projet, sans recourir à des implémentations préexistantes en ligne. Ainsi, aucune référence externe n’est nécessaire pour justifier l’origine du code.

1.1 Classificateur Bayésien

1.1.1 Classificateur Bayésien Naïf (GaussianNB)

Définition : Le classificateur naïf bayésien est un modèle probabiliste basé sur le théorème de Bayes avec une forte hypothèse d’indépendance conditionnelle entre les variables explicatives. Il est formulé comme suit :

$$P(y \mid x_1, \dots, x_n) \propto P(y) \prod_{i=1}^n P(x_i \mid y) \quad (1)$$

Hypothèse principale : chaque feature x_i est indépendante des autres conditionnellement à la classe y . Le modèle **GaussianNB** suppose de plus que chaque $x_i \mid y$ suit une distribution normale.

Implémentation : le modèle est entraîné sur les données équilibrées à l’aide de la méthode SMOTE. Trois versions ont été testées :

- Sans calibration,
- Calibration **sigmoïde** (Platt scaling),
- Calibration **isotonique** (plus souple, sans forme paramétrique).

Les performances ont été évaluées à l’aide du *rapport de classification*, des *courbes ROC* et des *courbes de calibration*.

1.1.2 Modèle Multinomial Naïve Bayes

Définition : Le classificateur bayésien multinomial est une variante du Naive Bayes adaptée aux **données discrètes**, souvent utilisée pour des modèles de texte ou des événements de comptage. Il estime les probabilités selon :

$$P(y | \mathbf{x}) \propto P(y) \prod_{i=1}^n P(x_i | y)^{x_i} \quad (2)$$

Hypothèse principale : les variables x_i sont des entiers positifs (ou discrétisées) représentant le nombre d'occurrences d'un événement.

Implémentation :

- Les variables continues ont été **discrétisées en 6 bins** via `KBinsDiscretizer`.
- Une **recherche fine du paramètre de lissage alpha** a été effectuée avec `GridSearchCV`, avec une précision allant jusqu'à 10^{-6} .
- Le meilleur modèle ($\alpha = 10^{-6}$) a ensuite été **calibré avec une régression isotonique**.

1.1.3 Réseau Bayésien non naïf

Définition : Un réseau bayésien est un **modèle graphique probabiliste** représentant un ensemble de variables et leurs dépendances conditionnelles via un graphe orienté acyclique (DAG). Il estime la probabilité jointe via :

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(x_i)) \quad (3)$$

Hypothèse principale : seules les dépendances explicitement modélisées dans la structure sont prises en compte.

Implémentation :

- Une **structure manuelle** a été imposée entre 5 variables sélectionnées.
- Les variables ont été **discrétisées** puis les paramètres appris avec un estimateur bayésien (`BayesianEstimator`).
- Les prédictions ont été réalisées par **inférence exacte** (`VariableElimination`).
- Les probabilités ont ensuite été **calibrées** pour vérifier leur qualité.

1.1.4 Régression logistique multinomiale pondérée

Définition : La régression logistique multinomiale est un modèle discriminatif qui prédit la probabilité qu'une observation appartienne à une classe parmi K . Elle est définie comme :

$$P(y = k | \mathbf{x}) = \frac{e^{\mathbf{x}^T \beta_k}}{\sum_{j=1}^K e^{\mathbf{x}^T \beta_j}}, \quad \text{pour } k \in \{0, 1, \dots, K\} \quad (4)$$

Implémentation :

- Utilisation du `solver='lbfgs'` avec `multi_class='multinomial'`.
- **Poids de classe automatiques** (`class_weight='balanced'`) calculés à partir de la distribution des classes dans le `dataset`.
- Évaluation complète avec `log loss`, courbes ROC, calibration et *classification report*.

1.2 Réseau de neurones avec propagation avant

Métrique d'évaluation quantitative

Pour évaluer quantitativement les performances du modèle de prédiction des buts (`home_goals` et `away_goals`), les métriques suivantes seront utilisées :

- Mean Absolute Error (MAE) :

Définition : La moyenne des valeurs absolues des différences entre les prédictions et les valeurs réelles.

Interprétation : Plus le MAE est faible, meilleure est la performance du modèle.

Formule :

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Root Mean Squared Error (RMSE) : Définition : La racine carrée de la moyenne des carrés des différences entre les prédictions et les valeurs réelles.

Interprétation : Pénalise davantage les grandes erreurs que le MAE.

Formule :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Ces métriques sont déjà calculées dans le code pour les buts à domicile (`home_goals`) et les buts à l'extérieur (`away_goals`), comme le montre la sortie suivante :

```
HomeGoals MAE: 0.9636885817156448
HomeGoals RMSE: 1.2440708649700725
AwayGoals MAE: 0.8368403724876429
AwayGoals RMSE: 1.0797697346483086
```

Étapes pour évaluer un résultat :

- Comparer les prédictions du modèle avec les résultats réels des matchs.
- Noter la pertinence des prédictions (par exemple, si le modèle prédit correctement le vainqueur ou un match nul).
- Évaluer la cohérence des prédictions sur une série de matchs.


Métriques qualitatives :

- Précision des prédictions de victoire/défaite/nul.
- Capacité à identifier des tendances (équipe en forme, etc.).

Conception et configuration pour l'évaluation qualitative du modèle

- Analyse des erreurs : Identifier les matchs où les prédictions sont les plus éloignées de la réalité et analyser les causes possibles (blessures, suspensions, etc.).

— Visualisation



— Configuration

- Architecture : Un réseau de neurones à deux sorties (`home_goals` et `away_goals`) avec des couches denses (64 et 32 neurones, activation ReLU).
- Fonction de perte : Mean Squared Error (MSE) pour les deux sorties.
- Optimiseur : Adam avec un taux d'apprentissage de 0.001.
- Métriques supplémentaires : MAE pour suivre la performance.
- Hyperparamètres :
 - Batch size : 32. Époques : 50 (avec arrêt précoce si la perte de validation ne s'améliore pas).
- Entraînement :
 - Données : 8947 échantillons pour l'entraînement, 2237 pour le test.
 - Préprocessing : Normalisation des features avec StandardScaler.
 - Early Stopping : Patience de 5 epochs pour éviter le surapprentissage.
- Observations : Les erreurs MAE et RMSE montrent que le modèle est plus performant à la prédiction des buts à l'extérieur qu'à l'intérieur (variance plus faible).

2 Expériences

2.1 Jeux de données

Pour prédire les matchs de la Premier League de manière fiable, notre projet utilise une variété de données statistiques au fil des années. Voici la définition de chaque colonne de données utilisées dans nos modèles prédictifs :

- **Unnamed : 0** : Index numérique des entrées.
- **Season** : La saison du match, indiquée par l'année (format YYYY-YY).
- **Date** : Date du match (format YYYY-MM-DD).
- **HomeTeam** : Nom de l'équipe jouant à domicile.
- **AwayTeam** : Nom de l'équipe visiteuse.

- **FTR** : Résultat final du match du point de vue de l'équipe à domicile ('H' pour victoire à domicile, 'D' pour nul, 'A' pour victoire à l'extérieur).
- **HomeGoals** : Nombre de buts marqués par l'équipe à domicile.
- **AwayGoals** : Nombre de buts marqués par l'équipe visiteuse.
- **StandingDiff** : Différence de classement entre les deux équipes avant le match.
- **HomeWins** : Pourcentage de victoires à domicile de l'équipe jouant à domicile.
- **AwayWins** : Pourcentage de victoires à l'extérieur de l'équipe visiteuse.
- **HomeDraws** : Pourcentage de matchs nuls à domicile de l'équipe jouant à domicile.
- **AwayDraws** : Pourcentage de matchs nuls à l'extérieur de l'équipe visiteuse.
- **AvgHomeGoals** : Moyenne de buts marqués à domicile par l'équipe jouant à domicile.
- **AvgAwayGoals** : Moyenne de buts marqués à l'extérieur par l'équipe visiteuse.
- **AvgHomeShots** : Moyenne de tirs par match à domicile de l'équipe jouant à domicile.
- **AvgAwayShots** : Moyenne de tirs par match à l'extérieur de l'équipe visiteuse.
- **AvgHomeShotsOnTarget** : Moyenne de tirs cadrés par match à domicile de l'équipe jouant à domicile.
- **AvgAwayShotsOnTarget** : Moyenne de tirs cadrés par match à l'extérieur de l'équipe visiteuse.
- **AvgHomeCorners** : Moyenne de corners obtenus par match à domicile de l'équipe jouant à domicile.
- **AvgAwayCorners** : Moyenne de corners obtenus par match à l'extérieur de l'équipe visiteuse.
- **AvgHomeGoalsConceded** : Moyenne de buts concédés à domicile par l'équipe jouant à domicile.
- **AvgAwayGoalsConceded** : Moyenne de buts concédés à l'extérieur par l'équipe visiteuse.
- **AvgHomeShotsConceded** : Moyenne de tirs subis par match à domicile de l'équipe jouant à domicile.
- **AvgAwayShotsConceded** : Moyenne de tirs subis par match à l'extérieur de l'équipe visiteuse.

Toutes ces données sont utilisées pour entraîner divers modèles prédictifs, y compris des réseaux de neurones, des forêts aléatoires et des modèles bayésiens, dans le but de prédire le plus précisément possible le classement final de chaque équipe de Premier League pour la saison à venir.

Nous avons délibérément choisi de commencer notre analyse à partir de la saison 2011-2012, car nous n'avons pas trouvé de données complètes et fiables pour les saisons précédentes. Cela s'explique en grande partie par le fait que les statistiques détaillées (comme les tirs cadrés, les corners, ou encore les données issues du tracking) et les outils technologiques permettant leur collecte n'étaient pas encore pleinement exploités avant cette période. L'évolution rapide des technologies d'analyse du sport a permis, à partir de 2011, une amélioration significative de la qualité et de la granularité des données disponibles.

Ce choix méthodologique n'est pas problématique, car dans le monde du football professionnel, les performances d'une équipe peuvent évoluer de manière spectaculaire en l'espace de seulement quelques saisons. Des exemples marquants illustrent cette dynamique : les Girondins de Bordeaux,

qui ont subi plusieurs relégations en l’espace de quatre ans ; le FC Barcelone, dont les performances ont connu des baisses notables durant les années 2020 ; ou encore la Juventus de Turin, finaliste de la Ligue des Champions en 2017, mais qui a rapidement perdu de son statut européen dans les saisons suivantes.

Ainsi, en nous concentrant sur les données à partir de la saison 2011-2012, nous maximisons la pertinence et l’actualité de notre modèle prédictif. Cette approche nous permet de mieux refléter l’état récent des clubs de Premier League, en nous appuyant sur des tendances récentes et des performances plus représentatives de leur niveau actuel. Elle garantit également une meilleure adaptabilité de nos prédictions à un championnat dynamique, où les cycles de performance peuvent se renverser rapidement.

2.2 Résultats expérimentaux

2.2.1 Classificateur Bayésien Naïf (GaussianNB)

Analyse du modèle Naive Bayes classique (Figure 1) Le modèle Naive Bayes non calibré présente une performance modérée avec une **exactitude globale de 0,57**. L’analyse du rapport de classification (Figure 1) révèle une forte asymétrie entre les classes. La classe 1 est particulièrement mal prédite, avec un *f1-score* de seulement 0,40, ce qui reflète les difficultés du modèle à gérer les classes minoritaires sans ajustement. Malgré une précision correcte sur les classes 0 et 2, le *recall* est faible sur la classe 2. Ces résultats soulignent les limites du modèle en présence de déséquilibres dans les données.

2.2.2 Naive Bayes multinomial calibré isotoniquement avec $\alpha = 10^{-6}$

Analyse du modèle Multinomial Naive Bayes calibré isotonique (Figure 2) Le modèle Multinomial Naive Bayes, combiné avec une calibration isotonique et un lissage optimal ($\alpha = 10^{-6}$), affiche une nette amélioration globale avec une **exactitude de 0,76** et un *f1-score moyen* de 0,76 (figure 2). Contrairement au modèle précédent, les performances sont équilibrées entre les trois classes, avec des *f1-scores* allant de 0,69 à 0,80. De plus, les valeurs AUC ROC sont élevées (macro = 0,89, micro = 0,90), ce qui indique une très bonne séparation des classes et une calibration fiable des probabilités. Ce modèle bénéficie clairement des ajustements effectués et montre une robustesse supérieure.

2.2.3 Réseau Bayésien non naïf

Analyse du modèle Réseau Bayésien (Figure ??) Le modèle basé sur un réseau bayésien, malgré sa capacité à modéliser les dépendances entre variables, présente des résultats inférieurs aux modèles précédents. Le rapport (??) indique une **exactitude globale de 0,52**, et des *f1-scores* très homogènes autour de 0,52 pour toutes les classes. Bien que cette homogénéité reflète une certaine stabilité du modèle, elle révèle également une difficulté à bien discriminer entre les classes. Le *log loss*, proche de 0,95, indique une calibration des probabilités moins satisfaisante. Ce modèle illustre donc les limites des approches structurelles bayésiennes simples dans des contextes multiclassés avec déséquilibre.

2.2.4 Conclusion partielle de Classificateur Bayésien

Parmi les variantes bayésiennes testées, le **modèle Multinomial Naive Bayes calibré isotoniement** se distingue par une précision correcte (76 %) et une excellente calibration des probabilités ($\text{AUC ROC} \approx 0.90$). Ces résultats confirment l'intérêt du lissage optimal combiné à une calibration non paramétrique.

Cependant, ces modèles reposent sur des caractéristiques extraites *après* les matchs (buts, tirs, corners), ce qui limite fortement leur usage pour une prédiction anticipée. En effet, pour prédire les résultats de la saison 2022–2023, il faudrait disposer à *l'avance* de ces mêmes données, ce qui est irréaliste.

Ainsi, bien que performants en rétro-analyse, les classificateurs bayésiens n'apportent pas de solution directe à notre objectif de prédiction des matchs à venir.

3 Conclusion

Parmi les modèles testés dans le cadre de ce projet, le Multinomial Naive Bayes calibré et la régression logistique multinomiale pondérée se distinguent nettement. Bien que les modèles bayésiens présentent l'avantage de la simplicité et d'une excellente calibration probabiliste, c'est bien la régression logistique pondérée qui offre les meilleurs résultats en termes de précision, de log loss et de traitement des classes déséquilibrées. Sa performance élevée, combinée à une interprétabilité conservée, en fait une solution à la fois puissante et accessible. Cela dit, malgré ces bons résultats,

les prédictions restent loin d'être parfaites. Comme évoqué dans les sections précédentes, de nombreux facteurs externes échappent à toute modélisation statistique. Des événements inattendus, tels qu'un transfert majeur à la fin du mercato, une blessure prolongée d'un joueur clé, ou même un changement d'entraîneur en cours de saison, peuvent profondément altérer les dynamiques collectives d'une équipe. À titre d'exemple, on peut rappeler la saison 2020-2021 de Liverpool, où

une série de blessures au sein de la défense centrale a totalement désorganisé l'équipe, malgré un effectif stable sur le papier. Ou encore le redressement spectaculaire de Newcastle United après son rachat et les investissements massifs effectués, illustrant l'effet instantané que des facteurs structurels peuvent avoir sur la compétitivité d'un club. Par ailleurs, de nombreuses données internes

aux clubs demeurent confidentielles : données biomédicales, rapports tactiques, charge mentale des joueurs, etc. L'ajout de ces dimensions nécessiterait la conception de modèles encore plus complexes, potentiellement hybrides, mêlant données structurées, séries temporelles, voire traitement de texte ou d'images. En définitive, toute équipe ou analyste cherchant à prédire les résultats des

matchs de Premier League doit envisager ces modèles comme des outils d'aide à la décision plutôt que des oracles. Bien utilisés, ils permettent d'éclairer des tendances, d'identifier des biais, et de simuler des scénarios, mais ils ne peuvent se substituer à une préparation rigoureuse, une lecture stratégique du calendrier, et une gestion humaine des imprévus qui façonnent, chaque année, la réalité du championnat anglais.

	precision	recall	f1-score	support
0	0.67	0.69	0.68	363
1	0.33	0.49	0.40	273
2	0.73	0.54	0.62	514
accuracy			0.57	1150
macro avg	0.58	0.57	0.57	1150
weighted avg	0.62	0.57	0.59	1150

FIGURE 1 – Rapport de classification du modèle Naive Bayes

===== Rapport de classification =====				
	precision	recall	f1-score	support
0	0.86	0.74	0.79	514
1	0.62	0.79	0.69	514
2	0.86	0.75	0.80	514
accuracy			0.76	1542
macro avg	0.78	0.76	0.76	1542
weighted avg	0.78	0.76	0.76	1542
Log Loss : 0.6168775811538239				
AUC ROC macro : 0.893710856081596				
AUC ROC micro : 0.9030342161795704				

FIGURE 2 – Rapport de classification du modèle Multinomial NB

	precision	recall	f1-score	support
0	0.57	0.47	0.52	1713
1	0.45	0.54	0.49	1713
2	0.56	0.54	0.55	1713
accuracy			0.52	5139
macro avg	0.53	0.52	0.52	5139
weighted avg	0.53	0.52	0.52	5139
Log Loss : 0.9470581958007861				

FIGURE 3 – Rapport de classification du modèle Naive Bayes calibré isotoniquement